Modelado y Simulación de Sistemas – FIUNER

Obtención de parámetros mediante Algoritmos Genéticos: aplicación al modelo SIR

Guía de Trabajos Prácticos N°2. Parte 2

1. Introducción

1.1. Motivación y planteo del problema

Uno de los desafíos centrales en la modelización de sistemas dinámicos es la identificación paramétrica: dada una estructura de modelo y una serie de datos observados, ¿cuáles son los valores de los parámetros que mejor reproducen el comportamiento del sistema real? En sistemas lineales estacionarios este problema admite solución analítica a través del método de cuadrados mínimos y la superficie de error cuadrático presenta un único mínimo global en forma de paraboloide, lo que garantiza que cualquier método de descenso converge a la solución óptima.

En sistemas no lineales la situación es cualitativamente distinta. La superficie de error en el espacio de parámetros puede presentar múltiples mínimos locales, valles planos, crestas y discontinuidades. Ante esa topografía irregular, los métodos basados en el gradiente de la función de costo —descenso del gradiente, Newton-Raphson, Levenberg-Marquardt— quedan fácilmente atrapados en óptimos locales y su desempeño depende fuertemente del punto de partida. Peor aún, en muchos sistemas físicos la función de costo solo puede evaluarse mediante simulación numérica, de modo que el gradiente no está disponible en forma analítica.

> *En sistemas no lineales o no estacionarios la superficie de error deja de ser convexa. Los métodos que explotan el gradiente son ineficaces o inaplicables cuando dicho gradiente no existe, es discontinuo, o la función objetivo es evaluable únicamente mediante integración numérica del modelo.*

El modelo epidemiológico SIR es un ejemplo paradigmático de esta situación: sus ecuaciones son no lineales, los datos disponibles son habitualmente ruidosos y escasos, y sus parámetros no pueden medirse directamente en el campo sino que deben inferirse a partir de curvas de casos observados. Los Algoritmos Genéticos (AG), inspirados en los mecanismos de la evolución biológica, constituyen una herramienta de búsqueda global capaz de sortear estas dificultades sin requerir información sobre el gradiente ni supuestos de convexidad.

Este trabajo introduce los fundamentos teóricos de los AG y propone como tarea la implementación computacional completa de un AG para estimar los parámetros β y γ del modelo SIR a partir de datos sintéticos con ruido.

2. El sistema no lineal

2.1. El modelo SIR de difusión epidémica

El modelo SIR, formulado por Kermack y McKendrick en 1927, describe la evolución temporal de tres compartimentos de una población cerrada de tamaño N: individuos susceptibles S(t), infectados I(t) y recuperados R(t). La dinámica está gobernada por el siguiente sistema de ecuaciones diferenciales ordinarias:

$$\frac{dS}{dt} = {-\beta S(t)I(t)}/{N} \qquad (1a)$$

$$\frac{dI}{dt} = {\beta S(t)I(t)}/{N} - \gamma \mathrm{I(T)} \qquad (1b)$$

$$\frac{dR}{dt} = \gamma \mathrm{I(T)} \qquad (1c)$$

con la restricción S(t) + I(t) + R(t) = N para todo t ≥ 0. Los dos parámetros libres del modelo son β, la tasa de transmisión —número promedio de contactos efectivos por unidad de tiempo entre un infectado y un susceptible— y γ, la tasa de recuperación, de manera que el período infeccioso medio es 1/γ.

El cociente $R_0 = \beta/\gamma$ es el número básico de reproducción. Cuando $R_0 > 1$ el número de infectados crece inicialmente y se produce una epidemia; cuando $R_0 \leq 1$ el brote se extingue. Este parámetro tiene gran relevancia en salud pública porque determina el umbral de cobertura vacunal necesario para lograr inmunidad de grupo: se requiere vacunar al menos la fracción $1 - 1/R_0$ de la población para suprimir la transmisión.

2.2. No linealidad y dificultad de identificación

El término β · S(t) · I(t) / N hace al sistema no lineal: la tasa de nuevos infectados depende del producto de las dos variables de estado, no de una combinación lineal de ellas. No existe una transformación que exprese β y γ como combinación lineal de observables, por lo que el método de cuadrados mínimos estático no es directamente aplicable.

Además, la superficie del Error Cuadrático Medio (ECM) en el espacio (β, γ) no es convexa: distintas combinaciones con el mismo cociente R_0 generan trayectorias de I(t) similares en las etapas tempranas de la epidemia, creando un valle elongado a lo largo de la dirección de R_0 constante. Evaluar cualquier función de costo requiere integrar numéricamente el sistema (1), por lo que la función objetivo es una caja negra sin gradiente analítico disponible. Por estas razones la identificación del modelo SIR es un problema de optimización global no convexo, apropiado para técnicas de computación evolutiva.

3. Marco teórico: Algoritmos Genéticos

3.1. Origen e inspiración biológica

Los Algoritmos Genéticos fueron desarrollados por John Henry Holland en la Universidad de Michigan durante los años 70, a partir de la observación de que los mecanismos de la evolución biológica constituyen una forma eficiente de búsqueda y adaptación en espacios de alta dimensionalidad. La idea central es que una población de soluciones candidatas evoluciona a lo largo de generaciones mediante operadores inspirados en la genética: selección de los individuos más aptos, cruzamiento del material genético entre progenitores, y mutación aleatoria de genes individuales.

A diferencia del lamarckismo, los AG siguen el paradigma darwiniano: la evolución ocurre a través de las generaciones sobre la población, no sobre los individuos. Un cromosoma no mejora durante su vida; son las poblaciones las que mejoran de generación en generación, lo que implica que la diversidad genética de la población es un recurso colectivo tan valioso como el desempeño de los mejores individuos.

3.2. Características distintivas

Los AG presentan cuatro características que los diferencian de los métodos de optimización convencionales. En primer lugar, trabajan con una codificación del espacio de soluciones —habitualmente una cadena de bits— y no directamente con los parámetros del problema. En segundo lugar, realizan una búsqueda poblacional: en cada generación se mantiene y evalúa un conjunto de N individuos. En tercer lugar, utilizan únicamente la información de la función objetivo, sin requerir sus derivadas. En cuarto lugar, emplean reglas de transición probabilísticas, lo que permite explorar globalmente el espacio de soluciones y escapar de mínimos locales con probabilidad no nula.

3.3. Estructura del algoritmo

El ciclo evolutivo de un AG canónico puede describirse mediante el siguiente pseudocódigo:

```
Inicializar(Población P0)        % generar N individuos aleatorios
BestFitness ← Evaluar(P0)

mientras BestFitness<FitnessRequerido y gen <maxGen:
    Padres       ← Selección(P)
    Descendencia ← Cruzamiento(Padres, Pc)
    Descendencia ← Mutación(Descendencia, Pm)
    P            ← Reemplazo(P, Descendencia)
BestFitness  ← Evaluar(P)

retornar mejor individuo de P    % solución encontrada
```

3.4. Representación de los individuos

Para la estimación de parámetros continuos la representación más habitual es la codificación binaria: cada parámetro se representa como una cadena de L bits que se decodifica a un valor real dentro de un rango predefinido. Para un parámetro p con rango [p_min, p_max] y L bits de resolución la decodificación es:

$$p = p_{\min} + (p_{max} - p_{min}) * decimal(b_1 b_2 \ldots b..L)/(2^L - 1) \qquad (2)$$

donde decimal($b_1 b_2 \ldots$b_L) es el valor entero de la cadena en base 2. Con L = 16 bits se obtiene una resolución de (p_max − p_min) / 65535. Para el modelo SIR con dos parámetros, cada individuo es un cromosoma de 32 bits: los primeros 16 codifican β y los 16 siguientes codifican γ.

3.5. Función de aptitud

La función de aptitud (fitness) cuantifica qué tan bien reproduce el modelo simulado los datos observados. Para un problema de minimización del error de predicción sobre la curva de infectados, una elección natural es el fitness invertido basado en el Error Cuadrático Medio:

$$\mathrm{ECM}(\beta,\ \gamma)\ =\ \frac{1}{T}\cdot\sum_{t=1}^{T}\left[\hat{I}(t\,;\ \beta,\gamma)\ -\ I_{\mathrm{obs}}(t)\right]^2 \tag{3}$$

$$\mathrm{fitness}(\beta,\ \gamma)\ =\ \frac{1}{1\ +\ \mathrm{ECM}(\beta,\ \gamma)} \tag{4}$$

donde Î(t ; β, γ) es la curva de infectados obtenida integrando numéricamente el sistema (1) con los parámetros propuestos, e I_obs(t) son los datos observados. El fitness vale 1 cuando el ajuste es perfecto y tiende a 0 cuando el ECM es grande.

3.6. Selección por ruleta proporcional

El operador de selección determina qué individuos participan como progenitores en la reproducción. La selección proporcional al fitness asigna a cada individuo i una probabilidad de selección proporcional a su fitness relativo dentro de la población:

$$P(\text{seleccionar individuo } i)\ =\ \frac{\mathrm{fitness}(i)}{\sum_{j=1}^{N}\mathrm{fitness}(j)} \tag{5}$$

```
P(seleccionar individuo i) = fitness(i) / Σ_{j=1}^{N} fitness(j)(5)
```

Este mecanismo premia a los más aptos sin excluir completamente a los menos aptos, preservando diversidad genética en la población.

3.7. Cruzamiento de un punto

El cruzamiento es el operador principal de exploración del espacio de parámetros: combina material genético de dos progenitores para producir descendientes que heredan características de ambos. En el cruzamiento de un punto se selecciona aleatoriamente un punto de corte k ∈ {1, …, L−1}:

$$\mathrm{hijo}_1\ =\ [\ \mathrm{padre}_1[1:k]\ \mid\ \mathrm{padre}_2[k{+}1:L]\ ] \tag{6a}$$

$$\mathrm{hijo}_2\ =\ [\ \mathrm{padre}_2[1:k]\ \mid\ \mathrm{padre}_1[k{+}1:L]\ ] \tag{6b}$$

El cruzamiento se aplica con probabilidad Pc: con probabilidad 1 − Pc los hijos son copias exactas de los padres. Un valor típico es Pc = 0.80.

3.8. Mutación bit a bit

La mutación actúa sobre cada gen de forma independiente: con probabilidad Pm cada bit se invierte (0 → 1 ó 1 → 0). Es el operador de diversificación: garantiza que el AG pueda alcanzar cualquier punto del espacio de búsqueda con probabilidad no nula, previniendo la convergencia prematura. La probabilidad de mutación debe ser baja —típicamente Pm ≈ 1/L— para no destruir soluciones buenas.

3.9. Elitismo

El elitismo garantiza que el mejor individuo de la generación actual pase sin modificación a la siguiente. Esto asegura que la curva del mejor fitness sea monótonamente no decreciente: una vez encontrada una buena solución, no puede perderse por acción de los operadores estocásticos.

4. Aplicación: identificación paramétrica del modelo SIR

El objetivo es encontrar los valores de β y γ que minimizan la discrepancia entre la trayectoria de infectados producida por el modelo y una serie temporal de casos observados. Formulado como problema de optimización, se busca:

$$(\beta^*, \gamma^*) = \underset{\beta,\,\gamma}{\arg\min}\ \mathrm{ECM}(\beta, \gamma) \quad \text{con:} \quad \beta \in [\beta_{\min}, \beta_{\max}], \quad \gamma \in [\gamma_{\min}, \gamma_{\max}] \tag{8}$$

El AG opera sobre esta función de costo sin asumir ninguna propiedad analítica: ni convexidad, ni diferenciabilidad, ni unimodalidad. Los datos de entrenamiento son los valores $I_obs(t_1)$, …, $I_obs(T)$ obtenidos directamente de la integración numérica del modelo SIR con los parámetros verdaderos, muestreados en instantes equiespaciados.

La codificación binaria de 16 bits por parámetro produce cromosomas de 32 bits. Cada evaluación del fitness requiere integrar numéricamente el sistema (1) con condiciones iniciales $S(0) = N - I_0$, $I(0) = I_0$, $R(0) = 0$. Con los parámetros propuestos, el número total de evaluaciones del modelo es 40 × 100 = 4000 integraciones numéricas, un costo perfectamente asumible en Python o MATLAB en tiempos de ejecución de pocos segundos.

5. Ejercicios

5.1. Obligatorio

Se propone implementar en Python o MATLAB un Algoritmo Genético canónico para estimar los parámetros β y γ del modelo SIR. El trabajo se divide en tres partes: generación de datos sintéticos, implementación del AG, y análisis de resultados.

Parte I — Generación de datos sintéticos

1. Implementar una función que integre numéricamente el sistema SIR (ecuaciones 1a–1c) mediante cualquier método numérico (Euler, Taylor, Runge-Kutta, etc.), con paso de integración $\Delta t = 0.5$ días y $N = 1000$ individuos.
2. Generar la trayectoria de referencia con los valores verdaderos $\beta_true = 0.30$ y $\gamma_true = 0.10$, condiciones iniciales $S(0) = 990$, $I(0) = 10$, $R(0) = 0$, durante $T = 60$ días. Verificar que el número básico de reproducción resultante es $R_0 = \beta/\gamma = 3.0$.
3. Muestrear $I(t)$ en 30 puntos equiespaciados a lo largo de los $T = 60$ días. Estos valores constituyen el vector I_obs que el AG deberá reproducir.

Parte II — Implementación del AG

1. Implementar la codificación y decodificación binaria de 16 bits por parámetro según la ecuación (2), usando los rangos de búsqueda indicados en el bloque de datos a continuación. Verificar que el cromosoma de todos ceros entrega β_min y γ_min, y el de todos unos entrega β_max y γ_max.
2. Implementar la función de fitness según las ecuaciones (3) y (4). Para cada individuo (β, γ), integrar el modelo SIR y calcular el ECM respecto a I_obs. Como verificación, los valores verdaderos deben producir un fitness igual a 1.
3. Implementar los tres operadores genéticos: selección por ruleta proporcional al fitness (ecuación 5), cruzamiento de un punto con probabilidad Pc (ecuación 6), y mutación bit a bit con probabilidad Pm.
4. Implementar el bucle evolutivo con inicialización aleatoria uniforme de la población. Incorporar elitismo: el mejor individuo de cada generación pasa sin modificación a la siguiente. Registrar en cada generación el mejor fitness y el fitness promedio de la población.

Parte III — Experimentos y análisis

1. Ejecutar el AG con los parámetros del bloque siguiente. Reportar los valores estimados β^* y γ^*, el error relativo porcentual de cada uno respecto a los valores verdaderos, y el $R_0^* = \beta^*/\gamma^*$ estimado frente al verdadero $R_0 = 3.0$.
2. Graficar en un mismo eje temporal la curva I_obs (trayectoria de referencia) y las curvas $S(t)$, $I(t)$, $R(t)$ simuladas con los parámetros estimados (β^*, γ^*). La superposición de I_obs con la curva de infectados estimada es la evidencia primaria de la calidad del ajuste.
3. Graficar la curva de convergencia: mejor fitness y fitness promedio de la población en función del número de generación. Discutir si el AG converge, a qué ritmo lo hace, y si se observan indicios de convergencia prematura.
4. **a. Resolución** — comparar $L = 4$, 8 y 16 bits. Se pide que el estudiante note que con L bits hay un error de cuantización mínimo de $(p_max - p_min)/(2^L - 1)$, lo que pone un piso a la precisión independientemente del AG.

   b. Rango de búsqueda — ampliar los rangos de β y γ y analizar si el AG sigue encontrando la solución cuando el espacio de búsqueda es más grande y la densidad de buenos individuos iniciales es menor.

c. Tamaño de población — comparar N = 10, 40 y 100 manteniendo el presupuesto total de evaluaciones constante en 4000 (ajustando generaciones), lo que obliga a pensar en el balance diversidad vs. velocidad.

d. Optativo — operador de selección alternativo — las tres variantes clásicas del material de la cátedra: selección por competencia (torneo), selección por ventana (windowing) y brecha generacional, con una descripción precisa de cada una para que el estudiante pueda implementarla directamente.

Parámetros fijados para todos los experimentos

```
Tamaño de población          N   =  100
Individuos Número de generaciones          =  50
Probabilidad de cruzamiento  Pc  =  0.80
Probabilidad de mutación     Pm  =  0.02
Bits por parámetro           L   =  16
Rango de búsqueda de  β  :   [ 0.05 ,  1.00 ]
 Rango de búsqueda de  γ  :   [ 0.01 ,  0.50 ]
Valores verdaderos (solo para generar I_obs; no deben revelarse al
AG):   β_true = 0.30   γ_true = 0.10   →
R0 = β_true / γ_true = 3.0
```

Entregables

a. Código fuente completo y comentado, con una función por operador genético.
b. Las gráficas pedidas en las consignas 2 y 3 de la parte III.
c. Tabla comparativa: parámetro, valor verdadero, valor estimado, error relativo (%).
d. Sección de discusión de no más de una página que analice el comportamiento del AG, discuta si el algoritmo converge adecuadamente, y proponga al menos una mejora posible al diseño utilizado.

5. Preguntas guía para la discusión

Las siguientes preguntas no requieren respuesta explícita con ese formato, pero deben quedar respondidas de manera implícita o explícita en la sección de discusión del informe.

- ¿Cuántas evaluaciones totales de la función de costo realiza el AG? ¿Es factible esa cantidad si cada integración numérica del modelo SIR toma del orden de milisegundos? ¿Cómo cambia ese número si se duplica el tamaño de la población o el número de generaciones?

- ¿Por qué la curva del mejor fitness es monótonamente no decreciente, mientras que la del fitness promedio puede oscilar e incluso descender entre generaciones? ¿Qué papel cumple el elitismo?
- ¿Qué ocurre con la diversidad de la población a medida que avanza la evolución? ¿Es posible que al cabo de 100 generaciones casi todos los individuos sean idénticos? ¿Qué consecuencias tendría eso y cómo se podría remediar?
- ¿Qué ocurre si I_obs se genera con un método numérico poco preciso (por ejemplo, Euler con paso grande)? ¿Puede el AG recuperar los parámetros verdaderos si la trayectoria de referencia tiene error de discretización significativo?

6. Bibliografía

Goldberg, D. E. (1989). GeneticAlgorithms in Search, Optimization and Machine Learning. Addison-Wesley, caps. 1, 3 y 4.

Holland, J. H. (1975). Adaptation in Natural and Artificial Systems. Universityof Michigan Press. Reimpreso por MIT Press, 1992.

Kermack, W. O. &McKendrick, A. G. (1927). A contributiontothemathematicaltheoryofepidemics. Proceedingsofthe Royal Societyof London A, 115(772), 700–721.

Michalewicz, Z. (1992). GeneticAlgorithms + Data Structures = EvolutionPrograms. Springer-Verlag.

Bäck, T., Hammel, U. &Schwefel, H.-F. (1997). Evolutionarycomputation: commentsonhistory and currentstate. IEEE TransactionsonEvolutionaryComputation, 1(1), 3–17.

Murray, J. D. (2002). MathematicalBiology I: AnIntroduction, 3.ª ed. Springer, cap. 10.